

基于大语言模型辅助的高维混沌系统长期预测建模

以 Lorenz-63 与 Lorenz-96 系统为例

钟兴涛 黄宇轩 郝致祺

学号：25120617 25120619 25120621

课程名称：人工智能导论

2026 年 6 月 10 日

摘要

本文研究混沌动力系统的长期多步预测问题。我们在大语言模型辅助下，先用 Lorenz-63 验证普通监督学习可拟合短期状态转移但难以稳定 rollout，再构建 10 维 Lorenz-96 数据集并比较 Baseline LSTM、PINN LSTM、Transformer、Hybrid LSTM 与 Ultimate Hybrid。实验以 500-step 累计 RMSE 为核心指标。结果表明，单步精度不能保证长期稳定；融合不完美 RK4 物理求解器、Transformer 残差模型、PINN 损失和 refined scheduled sampling 的 Ultimate Hybrid 取得最低最终累计 RMSE 12.80。本文说明，在高维混沌预测中，机器学习更适合作为物理模型的残差修正器。

关键词：大语言模型；Lorenz-96；高维混沌系统；长期预测；recursive rollout；Transformer；PINN；Hybrid correction

目录

1	引言	4
2	数据集构建与探索性分析	4
2.1	数据来源与特征描述	4
2.2	相关性热力图	5
2.3	数据预处理	5
3	基础铺垫：Lorenz-63 中的短期可学与长期受限	6
3.1	Lorenz-63 方程与实验目的	6
3.2	短期预测与 rollout 发散	7
4	Lorenz-96 高维混沌系统与多步预测定义	8
4.1	Lorenz-96 动力学方程	8
4.2	窗口序列预测	8
4.3	累计 RMSE 指标	8
5	从 Baseline LSTM 到 Ultimate Hybrid 的模型设计	9
5.1	Baseline LSTM 与状态增量学习	9
5.2	Scheduled Sampling: 缓解训练与 rollout 的分布偏移	9
5.3	PINN 物理约束: 限制非物理外推	10
5.4	Transformer: 增强历史窗口内的序列特征提取	10
5.5	不完美物理求解器与残差修正	10
5.6	Ultimate Hybrid 架构	11
6	Lorenz-96 实验结果与对比分析	11
6.1	阶段性 LSTM 优化结果	11
6.2	历史窗口长度消融	12
6.3	高级架构总体对比	13
6.4	预测散点分析	13
6.5	模块贡献分析	14
6.6	为什么单步精度不等于长期稳定性	15
7	讨论	15
7.1	物理模型与深度模型的分工	15
7.2	不同模块的局限	15
7.3	当前实验限制	15

8 结论	16
9 AI 协作反思	16
A 大模型交互与提示词工程实录	16
A.1 问题定义与架构设计指令	16
A.2 核心 Debug 记录	17
B 可复现性说明	17

1 引言

混沌系统预测的难点并不只在于单步预测误差，而在于长期递归推演中的误差放大。对于 Lorenz 这类确定性非线性动力系统，只要初始状态存在微小偏差，后续轨迹就可能迅速偏离真实演化。普通监督学习模型在测试集上取得较低 one-step RMSE，并不意味着它能够在 rollout 中稳定预测未来几百步。因此，本文关注的核心问题是：在高维混沌系统中，如何设计兼顾物理结构、序列记忆和长期稳定性的预测模型？

为了使问题逐步展开，本文先使用 Lorenz-63 系统作为基础验证。Lorenz-63 的三维结构简单、图像直观，适合说明短期局部状态转移可以被机器学习模型拟合，也适合展示 horizon 增大和 recursive rollout 带来的误差累积。但本文真正的重点是 Lorenz-96 (10D) 系统。相比 Lorenz-63，Lorenz-96 维度更高，变量间通过周期边界耦合，轨迹长期推演更容易暴露模型的稳定性问题。

本文的主要工作包括：

1. 使用 Lorenz-63 验证“短期可学、长期受限”的混沌预测现象，并将其作为后续高维模型设计的动机；
2. 对 Lorenz-96 (10D) 建立多步 recursive rollout 评价框架，明确累计 RMSE 是比单步误差更关键的指标；
3. 依次分析 Residual LSTM、PINN LSTM、Transformer、Hybrid LSTM 等设计对长期推演稳定性的影响；
4. 提出 Ultimate Hybrid 架构，将不完美物理求解器、Transformer 残差学习、PINN 物理约束和 refined scheduled sampling 融合；
5. 基于实际 CSV 输出和 rollout 曲线进行对比分析，说明各模块对长期稳定性的贡献与局限。

2 数据集构建与探索性分析

2.1 数据来源与特征描述

本文使用的样本不是直接下载的静态表格，而是由动力系统方程数值积分生成。Lorenz-63 部分包含 x, y, z 三个状态变量，并构造短期监督学习任务 $x(t + k\Delta t)$ ；Lorenz-96 部分包含 $N = 10$ 个耦合状态变量 $x_1, \dots, x_{10}$ ，核心任务是根据历史窗口预测下一时刻完整状态。所有实验数据均由 Python 脚本生成并保存到 `results/*.csv`，这样既保证了数据来源可追溯，也便于重复运行和检查。

从机器学习角度看，每一行样本都对应一个时间片或一个历史窗口。输入特征是当前或过去若干步的状态变量，输出目标是未来状态或状态增量。该设置与课程要求中的“输入变量-输出变量”关系一致：输入变量描述系统当前相空间位置和局部演化趋势，

输出变量描述系统下一步或未来若干步的状态。

2.2 相关性热力图

图 1 给出 Lorenz-63 基础数据中不同变量及未来目标之间的相关性热力图。可以看到，相邻时间状态之间存在明显相关性，但这种相关性并不意味着长期可预测。混沌系统的关键困难在于：局部相关和短期平滑能够帮助模型取得较好的 one-step 结果，而长期递归推演会反复放大每一步的小偏差。




图 1 Lorenz-63 监督学习数据的相关性热力图。热力图用于检查特征之间的线性相关结构，并说明短期局部状态具有可学习性。

2.3 数据预处理

预处理主要包括缺失值检查、时间顺序切分和标准化。首先，脚本检查生成数据中的缺失值，确认数值积分和窗口构造没有产生空值；其次，训练集与测试集按照时间顺序划分，而不是随机打乱，以避免未来信息泄漏；最后，对监督学习模型和神经网络输入使用 StandardScaler 标准化。

标准化的原因是 Lorenz 系统不同变量和不同预测目标的尺度并不完全一致，梯度下降模型会受到特征尺度影响。将特征变换为近似零均值、单位方差后，MLP、LSTM 和 Transformer 的训练更稳定，损失函数中的各维度误差也更具有可比性。对于树模型，标准化不是必需条件，但为了保持数据处理流程一致，本文仍在统一流水线中记录了标准化检查结果。

3 基础铺垫：Lorenz-63 中的短期可学与长期受限

3.1 Lorenz-63 方程与实验目的

经典 Lorenz-63 系统由三个耦合常微分方程组成：

$$\frac{dx}{dt} = \sigma(y - x), \quad (1)$$

$$\frac{dy}{dt} = x(\rho - z) - y, \quad (2)$$

$$\frac{dz}{dt} = xy - \beta z. \quad (3)$$

本文使用经典参数

$$\sigma = 10, \quad \rho = 28, \quad \beta = \frac{8}{3}. \quad (4)$$

基础轨迹由 `scipy.integrate.solve_ivp` 数值求解得到，初始状态为 $(1, 1, 1)$ ，模拟时间区间为 $[0, 50]$ ，采样点数为 10000。图 2 展示了生成的 Lorenz 吸引子。

Lorenz 系统三维吸引子




图 2 Lorenz-63 系统三维吸引子。该系统用于说明混沌预测中的短期拟合与长期发散问题。

Lorenz-63 部分不是本文最终模型的重点，而是用于回答一个基础问题：如果普通模型在短期预测中表现很好，它们能否自然推广到长期 rollout？实验结果给出的答案是否定的。

3.2 短期预测与 rollout 发散

表 1 给出课程原始短期任务 $x(t + 10\Delta t)$ 的测试集结果。Random Forest 和 MLP 明显优于 Linear Regression，说明短期局部非线性映射可以由监督学习模型拟合。

表 1 Lorenz-63 短期单变量预测结果（数据来源：results/model_metrics.csv）

模型	RMSE	MAE	R^2
Linear Regression	0.5457	0.4437	0.9952
Random Forest	0.0805	0.0507	0.9999
MLP	0.0757	0.0599	0.9999

然而，当 prediction horizon 扩大到 $k = 500$ 时，Random Forest 的状态 RMSE 上升到 10.9789，MLP 上升到 14.0980。更严格地，在 500 步 recursive rollout 中，模型只在初始时刻获得真实状态，之后不断使用自身预测作为下一步输入，最终累计 RMSE 如表 2 所示。

表 2 Lorenz-63 基础模型 500 步 recursive rollout 结果（数据来源：results/rollout_results.csv）

模型	最终累计 State RMSE
Linear Regression	20.2244
Random Forest	14.5356
MLP	19.8142




图 3 Lorenz-63 基础模型在递归推演中的累计误差。短期误差被反复输入下一步后，会逐渐转化为长期轨迹偏离。

这一结果构成后续 Lorenz-96 实验的动机：真正困难的不是 one-step fitting，而是 long-horizon stability。

4 Lorenz-96 高维混沌系统与多步预测定义

4.1 Lorenz-96 动力学方程

Lorenz-96 是常用于测试高维混沌预测方法的动力系统。本文采用 $N = 10$ 维系统：

$$\frac{dx_i}{dt} = (x_{i+1} - x_{i-2})x_{i-1} - x_i + F, \quad i = 1, \dots, N. \quad (5)$$

其中下标按周期边界处理：

$$x_{i+N} = x_i. \quad (6)$$

本文设定真实系统强迫项为

$$F_{\text{true}} = 8.0, \quad (7)$$

该设置使系统处于强混沌状态。数值模拟区间为 $[0, 100]$ ，采样点数为 10000，初始状态设为 F 附近的小扰动：

$$\mathbf{x}_0 = (F + 0.01, F, \dots, F). \quad (8)$$

训练集和测试集仍按时间顺序切分为前 80% 与后 20%，避免未来信息泄漏。

4.2 窗口序列预测

对于 Lorenz-96，模型输入不再是单个三维状态，而是长度为 w 的历史窗口：

$$\mathbf{X}_t = (\mathbf{x}_{t-w+1}, \mathbf{x}_{t-w+2}, \dots, \mathbf{x}_t) \in \mathbb{R}^{w \times N}. \quad (9)$$

one-step 序列预测可写为

$$\hat{\mathbf{x}}_{t+1} = f_\theta(\mathbf{X}_t). \quad (10)$$

但评估时采用 recursive rollout。给定初始真实窗口 $\mathbf{X}_t$ 后，模型预测一步，并把预测结果拼接回历史窗口：

$$\hat{\mathbf{x}}_{t+1} = f_\theta(\mathbf{x}_{t-w+1}, \dots, \mathbf{x}_t), \quad (11)$$

$$\hat{\mathbf{x}}_{t+2} = f_\theta(\mathbf{x}_{t-w+2}, \dots, \mathbf{x}_t, \hat{\mathbf{x}}_{t+1}), \quad (12)$$

$\vdots$

$$\hat{\mathbf{x}}_{t+m} = f_\theta(\hat{\mathbf{x}}_{t+m-w}, \dots, \hat{\mathbf{x}}_{t+m-1}). \quad (13)$$

因此，rollout 测试更接近真实长期预测场景，也更容易暴露模型稳定性问题。

4.3 累计 RMSE 指标

本文使用 500-step 最终累计 RMSE 评价长期推演：

$$\text{CRMSE}(T) = \sqrt{\frac{1}{T} \sum_{m=1}^T \|\mathbf{x}_{t+m} - \hat{\mathbf{x}}_{t+m}\|_2^2}. \quad (14)$$

与 one-step RMSE 相比, CRMSE(T) 同时反映每一步误差和误差在递归输入中的累积效应。本文后续所有 Lorenz-96 主要结果均以 $T = 500$ 的 CRMSE 为核心指标。

5 从 Baseline LSTM 到 Ultimate Hybrid 的模型设计

5.1 Baseline LSTM 与状态增量学习

时间序列预测的自然基线是 LSTM。直接预测绝对状态可以写为

$$\hat{\mathbf{x}}_{t+1} = f_{\theta}^{\text{LSTM}}(\mathbf{X}_t). \quad (15)$$

但在连续动力系统中, 相邻时间步之间的变化通常比绝对状态更容易学习。因此, 本文将 LSTM 改为残差形式:

$$\Delta \hat{\mathbf{x}}_{t+1} = g_{\theta}^{\text{LSTM}}(\mathbf{X}_t), \quad (16)$$

$$\hat{\mathbf{x}}_{t+1} = \mathbf{x}_t + \Delta \hat{\mathbf{x}}_{t+1}. \quad (17)$$

这一设计降低了学习目标的尺度, 也使模型形式更接近数值积分中的“当前状态 + 局部增量”。代码实现中, LSTM 输出最后时刻的隐藏状态, 经 LayerNorm 和全连接层得到 $\Delta \hat{\mathbf{x}}$, 并使用梯度裁剪缓解训练不稳定。

5.2 Scheduled Sampling: 缓解训练与 rollout 的分布偏移

one-step training 中, 模型每一步都看到真实历史窗口; 但 rollout 时, 模型会逐渐看到自己的预测值。这种差异称为 exposure bias 或 train-test mismatch。Scheduled sampling 的思想是在训练多步展开时, 以一定概率使用真实状态, 以互补概率使用模型预测状态构造下一步输入。

设第 e 个 epoch 的 teacher forcing 概率为 p_e 。普通线性衰减版本可写为

$$p_e = \max\left(0, 1 - \frac{e}{0.8E}\right), \quad (18)$$

其中 E 为总训练轮数。Ultimate Hybrid 中使用更平滑的反 Sigmoid 衰减:

$$p_e = \frac{k}{k + \exp(e/(E/10))}. \quad (19)$$

训练时展开 $M = 5$ 步, 损失取多步平均:

$$\mathcal{L}_{\text{multi}} = \frac{1}{M} \sum_{m=1}^M \text{MSE}(\hat{\mathbf{x}}_{t+m}, \mathbf{x}_{t+m}). \quad (20)$$

这使模型在训练阶段提前接触部分“非真实输入”, 从而更接近 rollout 环境。

5.3 PINN 物理约束：限制非物理外推

纯数据驱动模型在长期外推时可能生成不符合动力学方程的状态更新。为此，本文引入物理信息神经网络（PINN）思想 [4]。Lorenz-96 的真实向量场记为

$$\mathbf{f}_{L96}(\mathbf{x}; F_{\text{true}}). \quad (21)$$

模型一步预测产生的有限差分导数为

$$\frac{\hat{\mathbf{x}}_{t+1} - \mathbf{x}_t}{\Delta t}. \quad (22)$$

PINN 物理损失定义为

$$\mathcal{L}_{phys} = \left\| \frac{\hat{\mathbf{x}}_{t+1} - \mathbf{x}_t}{\Delta t} - \mathbf{f}_{L96}(\mathbf{x}_t; F_{\text{true}}) \right\|_2^2. \quad (23)$$

总损失写为

$$\mathcal{L} = \mathcal{L}_{data} + \lambda \mathcal{L}_{phys}, \quad (24)$$

代码中取 $\lambda = 0.1$ 。该约束不是要求模型完全等同于物理求解器，而是在数据拟合之外惩罚明显违背 Lorenz-96 动力学的更新方向。

5.4 Transformer：增强历史窗口内的序列特征提取

LSTM 通过递归结构处理历史窗口，长程依赖容易受到隐藏状态压缩限制。Transformer 使用 self-attention，在窗口内直接建立不同时间步之间的关联 [3]。本文的 Transformer 模型先将每个 10 维状态嵌入到 64 维空间，加入位置编码后通过两层 TransformerEncoder 处理：

$$\mathbf{Z}_t = \text{PE}(\text{Linear}(\mathbf{X}_t)), \quad (25)$$

$$\mathbf{H}_t = \text{TransformerEncoder}(\mathbf{Z}_t), \quad (26)$$

$$\Delta \hat{\mathbf{x}}_{t+1} = W \mathbf{H}_{t,-1} + b. \quad (27)$$

这一结构使模型能够更灵活地利用历史窗口中的局部振荡、相空间方向和短期演化趋势。

5.5 不完美物理求解器与残差修正

现实科学问题通常不是完全没有物理模型，而是已有近似模型。本文构造不完美 Lorenz-96 物理求解器：

$$F_{\text{imp}} = 8.5, \quad F_{\text{true}} = 8.0. \quad (28)$$

设 $\Phi_{\Delta t}^{F_{\text{imp}}}$ 表示使用 F_{imp} 的 RK4 一步求解器：

$$\mathbf{x}_{t+1}^{phys} = \Phi_{\Delta t}^{F_{\text{imp}}}(\mathbf{x}_t). \quad (29)$$

Hybrid 模型不直接从零预测 $\mathbf{x}_{t+1}$ ，而是学习物理求解器残差：

$$\Delta \hat{\mathbf{x}}_{t+1}^{res} = g_{\theta}(\mathbf{X}_t), \quad (30)$$

$$\hat{\mathbf{x}}_{t+1} = \mathbf{x}_{t+1}^{phys} + \Delta \hat{\mathbf{x}}_{t+1}^{res}. \quad (31)$$

这样做的好处是，物理求解器承担主要演化方向，神经网络只需修正由参数偏差和数值近似带来的系统误差。

5.6 Ultimate Hybrid 架构

Ultimate Hybrid 是本文的核心模型，其组成可以概括为：

1. 使用 $F_{\text{imp}} = 8.5$ 的不完美 RK4 物理求解器产生基础预测 $\mathbf{x}_{t+1}^{phys}$ ；
2. 使用 Transformer 从历史窗口 $\mathbf{X}_t$ 中提取时序特征并预测残差；
3. 使用 PINN 损失约束预测更新方向接近真实 Lorenz-96 向量场；
4. 使用 refined scheduled sampling 进行 5 步展开训练，减小训练和 rollout 之间的分布偏移。

数学上，Ultimate Hybrid 的一步预测可写为

$$\hat{\mathbf{x}}_{t+1} = \Phi_{\Delta t}^{F_{\text{imp}}}(\mathbf{x}_t) + g_{\theta}^{\text{Transformer}}(\mathbf{x}_{t-w+1}, \dots, \mathbf{x}_t). \quad (32)$$

训练目标为

$$\mathcal{L}_{UH} = \frac{1}{M} \sum_{m=1}^M \left[\text{MSE}(\hat{\mathbf{x}}_{t+m}, \mathbf{x}_{t+m}) + \lambda \left\| \frac{\hat{\mathbf{x}}_{t+m} - \tilde{\mathbf{x}}_{t+m-1}}{\Delta t} - \mathbf{f}_{L96}(\tilde{\mathbf{x}}_{t+m-1}; F_{\text{true}}) \right\|_2^2 \right], \quad (33)$$

其中 $\tilde{\mathbf{x}}_{t+m-1}$ 表示 scheduled sampling 后用于当前步输入的状态，可能是真实状态，也可能是模型上一时刻预测状态。该公式体现了三层约束：数据拟合、物理一致性和 rollout 暴露训练。

6 Lorenz-96 实验结果与对比分析

6.1 阶段性 LSTM 优化结果

表 3 总结了 Lorenz-96 LSTM 优化过程中的代表性结果。Baseline LSTM 在 one-step 指标上可以达到较高精度，但 500 步 rollout 仍会积累明显误差。Residual learning、LayerNorm 和梯度裁剪带来较稳定的 Phase 1 结果；然而，简单 scheduled sampling 并不总是改善长期推演，Phase 2 的最终累计 RMSE 反而上升到 14.1880。这说明混沌系统中多步训练策略需要谨慎设计，不能机械地认为“训练时多展开几步”一定更好。

该表最重要的启示是：one-step RMSE 从 0.0417 降到 0.0356，并没有带来更好的 500-step rollout。这正是本文强调长期累计误差的原因。

表 3 Lorenz-96 LSTM 阶段性优化结果

模型阶段	One-step RMSE	One-step R^2	500-step 最终累计 RMSE
Baseline LSTM (绝对状态预测)	0.7360	0.9531	13.9662
Phase 1: 残差预测 + LayerNorm + 裁剪	0.0417	0.9999	13.1749
Phase 2: 多步损失 + Scheduled Sampling	0.0356	0.9999	14.1880

6.2 历史窗口长度消融

历史窗口长度 w 决定模型能够看到多少过去状态。过短窗口可能缺少相空间信息，过长窗口则可能引入冗余混沌噪声，使训练和外推更加困难。表 4 和图 4 给出窗口长度消融结果。

表 4 Lorenz-96 LSTM 历史窗口长度消融 (数据来源: results/lstm_phase3_summary.csv)

窗口长度 w	500-step 最终累计 RMSE
10	15.7545
20	16.5752
50	111.0108



图 4 Lorenz-96 窗口长度消融。过长窗口 $w = 50$ 显著恶化长期推演，说明高维混沌序列中历史信息并非越长越好。

从结果看， $w = 50$ 发生严重退化，最终累计 RMSE 达到 111.0108。本文最终高级架构采用 $w = 20$ ，是对历史信息量、训练成本和模型稳定性的折中。

6.3 高级架构总体对比

表 5 给出高级模型在 Lorenz-96 500-step rollout 中的最终累计 RMSE。Baseline LSTM 的误差为 148.79，表现最差；PINN、Transformer、Refined SS 和 Hybrid LSTM 都显著降低误差；Ultimate Hybrid 最终达到 12.80，是所有比较模型中最优的。

表 5 Lorenz-96 (10D) 高级架构 500-step rollout 对比（数据来源：results/advanced/summary.csv）

模型架构	最终累计 State RMSE
Baseline LSTM	148.79
PINN LSTM	20.18
Refined SS LSTM	16.79
Transformer	16.34
Hybrid LSTM	15.84
Ultimate Hybrid	12.80




图 5 Lorenz-96 高级模型 500 步 rollout 累计 RMSE 曲线。Ultimate Hybrid 在整个测试窗口中保持较低误差，并取得最低最终累计 RMSE。

6.4 预测散点分析

按照课程项目对“真实值 vs. 预测值”散点图的要求，图 6 展示 Lorenz-63 短期预测任务中 Random Forest 的预测散点。大部分点分布在对角线附近，说明模型能够较好地拟合局部短期映射；在 x 取值绝对值较大的区域，散点离散程度略有增大，表明极端状态下局部非线性更强，模型预测更容易出现偏差。

需要强调的是，散点图主要反映 one-step 或短 horizon 的拟合质量，而不能直接代

表长期 rollout 稳定性。本文后续 Lorenz-96 结果显示，即便单步散点较接近对角线，递归推演时误差仍可能因混沌敏感性迅速积累。因此，散点分析用于验证局部预测是否合理，累计 RMSE 曲线则用于评价长期动力学稳定性。




图 6 Lorenz-63 短期预测任务的真实值与预测值散点图。多数点靠近对角线，说明模型具备较好的短期局部拟合能力，但极端状态下仍存在更明显偏差。

6.5 模块贡献分析

从表 5 可以看出，不同模块对应不同类型的稳定性改进。

首先，PINN LSTM 相比 Baseline LSTM 大幅降低误差，说明对预测导数施加物理约束能够有效减少非物理外推。即使模型仍是 LSTM，物理损失也为更新方向提供了额外限制。

其次，Transformer 的结果优于 Refined SS LSTM，说明 self-attention 对历史窗口内部关系的建模能力有助于捕捉高维相空间的短期演化趋势。它不依赖单个递归隐藏状态压缩全部历史信息，因此在窗口特征提取上更灵活。

第三，Hybrid LSTM 比纯 Transformer 和 Refined SS LSTM 略优，说明不完美物理求解器即使存在参数偏差，仍能提供有价值的动力学基底。神经网络只学习残差，比完全从数据中学习整个状态转移更容易。

最后，Ultimate Hybrid 将上述优势叠加：物理求解器提供基础演化，Transformer 提供残差表达能力，PINN 限制非物理更新，scheduled sampling 使训练过程更接近 rollout。它不是单一技巧的改进，而是针对长期混沌推演问题的组合式架构设计。

6.6 为什么单步精度不等于长期稳定性

本文结果反复说明 one-step RMSE 和 rollout RMSE 之间并非单调对应。造成这种现象的原因包括：

1. one-step 测试使用真实历史窗口，而 rollout 使用模型预测历史窗口；
2. 高维混沌系统会放大每一步的小误差；
3. 模型预测一旦偏离真实吸引子附近，后续输入分布就会偏离训练数据；
4. 低 one-step MSE 可能来自局部平均意义上的拟合，而非保持动力学结构。

因此，本文认为高维混沌预测的核心指标应是长期 rollout 稳定性，而不是单步误差。

7 讨论

7.1 物理模型与深度模型的分工

Ultimate Hybrid 的设计体现了 AI for Science 中一种重要思想：机器学习不必替代物理模型，而应与物理模型分工协作。对 Lorenz-96 而言，不完美 RK4 求解器已经包含主要动力学结构，Transformer 只需学习参数偏差和模型误差导致的残差。这样的任务分解比直接学习完整状态转移更稳定，也更符合科学建模中“已有近似方程，需要数据修正”的实际场景。

7.2 不同模块的局限

Residual learning 能降低学习难度，但不能保证长期稳定；scheduled sampling 能缓解训练和 rollout 的分布偏移，但若衰减策略不合适，也可能使模型过早暴露于噪声预测；PINN loss 能约束更新方向，但需要合理的权重 λ ；Transformer 增强历史建模，但参数更多、训练成本更高；Hybrid physics 依赖物理模型结构基本正确，如果物理模型严重错误，残差学习也可能失效。

7.3 当前实验限制

本文实验仍有课程项目规模限制。首先，Lorenz-96 只测试了 $N = 10$ 和 $F = 8.0$ 的设置，没有系统考察不同维度和强迫项。其次，模型训练轮数统一为 20，未进行大规模超参数搜索。第三，结果主要来自单随机种子，尚未报告多随机种子的均值和方差。最后，Ultimate Hybrid 的每个模块虽然都有对比，但还可以进一步做严格的 full ablation，例如 Transformer + PINN、Transformer + Hybrid、Hybrid + PINN 等组合对照。

8 结论

本文从 Lorenz-63 的基础监督学习实验出发，说明短期局部状态转移可以被机器学习拟合，但长期 recursive rollout 会受到混沌误差放大的限制。随后，本文将重点转向 Lorenz-96 (10D) 高维混沌系统，围绕 500-step rollout 稳定性设计并比较多种深度学习架构。

实验表明，单步预测精度不能代表长期预测能力。Residual LSTM、PINN、Transformer、Hybrid physics 和 scheduled sampling 分别从学习目标、物理一致性、序列建模、动力学基底和训练分布偏移等角度改善长期推演。最终的 Ultimate Hybrid 将不完美物理求解器、Transformer 残差建模、PINN 损失与 refined scheduled sampling 融合，在 Lorenz-96 500 步 rollout 中取得最低最终累计 RMSE 12.80。

总体而言，本文的核心结论是：高维混沌系统长期预测不应只依赖黑箱单步监督学习，更有效的路线是以物理模型为演化基底，以深度学习模型学习残差，并通过多步训练和物理约束提升 rollout 稳定性。

9 AI 协作反思

本项目中，LLM 主要用于选题拆解、实验路线讨论、代码调试提示、结果整理和报告结构重写。它帮助我们意识到“单步预测得分很高”并不是一个充分研究结论，并推动项目从 Lorenz-63 的基础监督学习扩展到 Lorenz-96 的长期多步预测架构设计。

同时，LLM 生成的解释必须接受代码和数据验证。本文所有表格中的数值均来自实际 CSV 输出，公式和模型描述也根据 Python 脚本中的实现进行核对。LLM 在本项目中的定位是协作工具，而不是实验结论本身的来源。

A 大模型交互与提示词工程实录

A.1 问题定义与架构设计指令

在项目早期，我们向 LLM 提出的核心问题是：“我们已经能用 MLP 和 Random Forest 对 Lorenz-63 做短期预测，但长期 rollout 很快发散。请帮助我们把这个课程项目扩展成一个更能体现 AI for Science 思想的机器学习建模问题，并给出适合比较的模型路线。” LLM 的反馈不是直接给出最终结论，而是建议把评价重点从 one-step RMSE 转向 recursive rollout，并进一步引入 Lorenz-96 作为高维混沌系统案例。

根据该建议，我们将研究问题明确为：给定 Lorenz-96 的历史窗口，预测未来状态并保持 500-step rollout 稳定。LLM 还建议按“纯数据驱动模型—物理约束模型—物理残差混合模型”的顺序展开，这最终形成了 Baseline LSTM、PINN LSTM、Transformer、Hybrid LSTM 和 Ultimate Hybrid 的模型演进结构。

A.2 核心 Debug 记录

一次典型调试发生在 LSTM 从单步训练扩展到多步 scheduled sampling 时。最初代码只在真实窗口上训练 one-step prediction, rollout 时却不断把预测拼回窗口, 导致训练和测试分布不一致。我们把张量形状、窗口更新代码和报错信息一起发给 LLM, 请它检查“预测状态如何拼接回形状为 `[batch, window, dim]` 的历史窗口”。LLM 指出应当在时间维度上丢弃最旧状态, 再把 `pred.unsqueeze(1)` 拼到窗口末尾。

这次交互带来的反思是: LLM 并不知道我们的数据维度、窗口长度和状态变量数, 只有在提示词中给出 `X.shape`、`pred.shape`、窗口更新逻辑和完整错误信息时, 它的建议才具有可执行性。后续我们也不再直接接受 LLM 生成的代码, 而是以 CSV 输出、图表和 LaTeX 表格互相核对, 确保报告中的每个数值都来自实际实验。

B 可复现性说明

本文主要实验代码包括:

- `lorenz_chaos_prediction.ipynb`: Lorenz-63 基础监督学习与 Hybrid correction;
- `lorenz96_lstm.py`、`lorenz96_lstm_phase2.py`、`lorenz96_lstm_phase3.py`: Lorenz-96 LSTM 阶段性优化;
- `lorenz96_advanced_experiments.py`: PINN、Transformer、Hybrid LSTM 与 Ultimate Hybrid 对比。

基础结果保存在 `results/*.csv`, 高级架构结果保存在 `results/advanced/*.csv`。报告中的 Lorenz-96 高级对比表来自 `results/advanced/summary.csv`, rollout 曲线由各模型对应的 `*_rollout.csv` 绘制。

参考文献

- [1] Lorenz, E. N. (1963). Deterministic nonperiodic flow. *Journal of the Atmospheric Sciences*, 20(2), 130–141.
- [2] Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780.
- [3] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*.
- [4] Raissi, M., Perdikaris, P., & Karniadakis, G. E. (2019). Physics-informed neural networks: A deep learning framework for solving forward and inverse problems in-

volving nonlinear partial differential equations. *Journal of Computational Physics*, 378, 686–707.

- [5] Pedregosa, F., Varoquaux, G., Gramfort, M., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, M., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- [6] Virtanen, P., Gommers, R., Oliphant, M., Haberland, M., Reddy, T., Cournapeau, D., Peterson, P., Weckesser, W., Bright, J., van der Walt, S., Brett, M., Wilson, J., Millman, K., Mayorov, N., Nelson, A., Jones, E., Kern, R., Larson, E., Carey, C., Polat, I., Feng, Y., Moore, E., VanderPlas, J., Laxalde, D., Perktold, J., Cimrman, R., Henriksen, I., Quintero, E., Harris, C., Archibald, A., Ribeiro, A., Pedregosa, F., & van Mulbregt, P. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods*, 17, 261–272.