

基于大语言模型辅助的 高维混沌系统长期预测建模

Lorenz-63 铺垫与 Lorenz-96 10D Ultimate Hybrid

钟兴涛 黄宇轩 郝致祺

人工智能导论课程项目

2026 年 6 月 10 日

汇报主线

- 1 问题动机
- 2 多步预测定义
- 3 模型演进
- 4 实验结果
- 5 总结

真正的问题不是 one-step, 而是 rollout


单步预测看起来容易

- 输入真实历史状态;
- 预测下一步或短 horizon;
- 测试分布接近训练分布。

长期推演才是难点

- 后续输入来自模型自己的预测;
- 小误差被混沌动力学放大;
- 轨迹逐渐偏离真实吸引子附近。

Lorenz 系统三维吸引子



Lorenz


吸引子：短期连续，长期敏感

Lorenz-63: 基础模型可以短期拟合, 但 rollout 会发散

模型	短期 RMSE	500-step RMSE
Linear Reg.	0.5457	20.2244
Random Forest	0.0805	14.5356
MLP	0.0757	19.8142

启示

Lorenz-63 证明: 短期局部映射可学, 但不能说明长期轨迹稳定。




基础模型 recursive rollout 误差累积

数据构建与可视化检查


数据与预处理

数值积分生成状态序列；按时间顺序切分训练/测试集；检查缺失值，并用 StandardScaler 统一尺度。



期局部状态可学习

相关性热力图：验证短



真实值 vs. 预测值：极端状态下偏差更明显

汇报时强调

散点图说明短期拟合较好，但长期能力必须用 500-step rollout 单独评价。

Lorenz-96 动力学

$$\frac{dx_i}{dt} = (x_{i+1} - x_{i-2})x_{i-1} - x_i + F, \quad i = 1, \dots, N$$

$$x_{i+N} = x_i, \quad N = 10, \quad F_{\text{true}} = 8.0$$

- 变量维度更高，耦合关系更复杂；
- 周期边界使每个变量依赖邻近状态；
- 500-step rollout 更能暴露长期稳定性。

本文核心问题

如何设计一个兼顾物理结构、历史窗口特征和 rollout 稳定性的模型？

窗口序列预测

历史窗口

$$\mathbf{X}_t = (\mathbf{x}_{t-w+1}, \mathbf{x}_{t-w+2}, \dots, \mathbf{x}_t) \in \mathbb{R}^{w \times N}$$

One-step prediction

$$\hat{\mathbf{x}}_{t+1} = f_{\theta}(\mathbf{X}_t)$$

问题

One-step evaluation 使用真实窗口; rollout evaluation 会不断把模型预测拼回窗口。

$$\begin{aligned}\hat{\mathbf{x}}_{t+1} &= f_{\theta}(\mathbf{x}_{t-w+1}, \dots, \mathbf{x}_t), \\ \hat{\mathbf{x}}_{t+2} &= f_{\theta}(\mathbf{x}_{t-w+2}, \dots, \mathbf{x}_t, \hat{\mathbf{x}}_{t+1}), \\ \hat{\mathbf{x}}_{t+m} &= f_{\theta}(\hat{\mathbf{x}}_{t+m-w}, \dots, \hat{\mathbf{x}}_{t+m-1}).\end{aligned}$$

500-step 累计 RMSE

$$\text{CRMSE}(T) = \sqrt{\frac{1}{T} \sum_{m=1}^T \|\mathbf{x}_{t+m} - \hat{\mathbf{x}}_{t+m}\|_2^2}, \quad T = 500$$

评价重点

本文不只看 one-step RMSE, 而以 500-step CRMSE 衡量长期推演稳定性。

第一步: Baseline LSTM 到 Residual LSTM

直接预测

$$\hat{\mathbf{x}}_{t+1} = f_{\theta}^{\text{LSTM}}(\mathbf{X}_t)$$

残差预测

$$\Delta \hat{\mathbf{x}}_{t+1} = g_{\theta}^{\text{LSTM}}(\mathbf{X}_t)$$

$$\hat{\mathbf{x}}_{t+1} = \mathbf{x}_t + \Delta \hat{\mathbf{x}}_{t+1}$$

- 连续动力系统相邻状态变化较小;
- 学习增量比学习绝对状态更容易;
- 加入 LayerNorm 与 gradient clipping 提升训练稳定性。

核心直觉

残差学习让模型更像一个数据驱动的局部积分器。

第二步: Scheduled Sampling 缓解分布偏移

训练时多步展开

$$\mathcal{L}_{multi} = \frac{1}{M} \sum_{m=1}^M \text{MSE}(\hat{\mathbf{x}}_{t+m}, \mathbf{x}_{t+m}), \quad M = 5$$

Refined inverse-sigmoid schedule

$$p_e = \frac{k}{k + \exp(e/(E/10))}$$

- 以概率 p_e 使用真实状态;
- 以概率 $1 - p_e$ 使用模型预测;
- 训练阶段更接近 rollout 环境。

注意

Scheduled sampling 不是总能改善结果, 衰减策略和多步展开方式很关键。

第三步: PINN 物理约束

Lorenz-96 向量场

$$\mathbf{f}_{L96}(\mathbf{x}; F) = ((x_{i+1} - x_{i-2})x_{i-1} - x_i + F)_{i=1}^N$$

有限差分导数与物理导数对齐

$$\mathcal{L}_{phys} = \left\| \frac{\hat{\mathbf{x}}_{t+1} - \mathbf{x}_t}{\Delta t} - \mathbf{f}_{L96}(\mathbf{x}_t; F_{\text{true}}) \right\|_2^2$$

总损失

$$\mathcal{L} = \mathcal{L}_{data} + 0.1\mathcal{L}_{phys}$$

第四步：Transformer 捕捉历史窗口关系

$$\mathbf{Z}_t = \text{PE}(\text{Linear}(\mathbf{X}_t)),$$

$$\mathbf{H}_t = \text{TransformerEncoder}(\mathbf{Z}_t),$$

$$\Delta \hat{\mathbf{x}}_{t+1} = W\mathbf{H}_{t,-1} + b.$$

- LSTM 用单个隐藏状态压缩历史;
- Transformer 通过 self-attention 建立窗口内时间步关联;
- 更适合捕捉高维相空间中的局部演化趋势。

第五步：不完美物理求解器 + 残差学习

不完美物理基底

$$F_{\text{true}} = 8.0, \quad F_{\text{imp}} = 8.5$$

$$\mathbf{x}_{t+1}^{\text{phys}} = \Phi_{\Delta t}^{F_{\text{imp}}}(\mathbf{x}_t)$$


Hybrid prediction

$$\hat{\mathbf{x}}_{t+1} = \mathbf{x}_{t+1}^{\text{phys}} + g_{\theta}(\mathbf{X}_t)$$

设计思想

物理求解器负责主要动力学演化，神经网络只学习参数偏差和模型误差导致的残差。

Ultimate Hybrid: 最终架构



Ultimate Hybrid: 统一公式

一步预测

$$\hat{\mathbf{x}}_{t+1} = \Phi_{\Delta t}^{F_{\text{imp}}}(\mathbf{x}_t) + g_{\theta}^{\text{Transformer}}(\mathbf{x}_{t-w+1}, \dots, \mathbf{x}_t)$$

多步训练目标

$$\mathcal{L}_{UH} = \frac{1}{M} \sum_{m=1}^M \left[\text{MSE}(\hat{\mathbf{x}}_{t+m}, \mathbf{x}_{t+m}) + \lambda \mathcal{L}_{phys}^{(m)} \right]$$

四个组件

不完美物理基底 + Transformer 残差 + PINN 约束 + 5 步 refined scheduled sampling。

阶段性 LSTM 优化：单步更好不代表 rollout 更好

模型阶段	One-step RMSE	One-step R^2	500-step RMSE
Baseline LSTM	0.7360	0.9531	13.9662
Phase 1: 残差 + LN + 裁剪	0.0417	0.9999	13.1749
Phase 2: 多步 + Scheduled Sampling	0.0356	0.9999	14.1880

关键观察


Phase 2 的 one-step RMSE 更低，但 500-step RMSE 更高。因此长期稳定性必须单独评估。

窗口长度消融：历史不是越长越好

窗口长度 w	500-step RMSE
10	15.7545
20	16.5752
50	111.0108


解释

过长窗口会引入冗余混沌信息，使训练和外推更不稳定。



高级模型总体对比

模型	500-step RMSE
Baseline LSTM	148.79
PINN LSTM	20.18
Refined SS LSTM	16.79
Transformer	16.34
Hybrid LSTM	15.84
Ultimate Hybrid	12.80



模块贡献分析

物理约束

PINN LSTM 从 148.79 降到 20.18, 说明物理导数约束能抑制非物理外推。

物理基底

Hybrid LSTM 达到 15.84, 说明不完美物理模型仍能提供有效演化方向。

序列建模

Transformer 达到 16.34, 说明 self-attention 能更好提取历史窗口特征。

组合架构

Ultimate Hybrid 达到 12.80, 来自物理基底、残差模型、物理损失和多步训练的协同。

为什么 Ultimate Hybrid 最好?

- ① **物理基底降低漂移**: RK4 求解器给出合理的一步演化方向;
- ② **残差学习降低难度**: 神经网络只修正 $F_{\text{imp}} = 8.5$ 带来的系统偏差;
- ③ **Transformer 利用历史**: self-attention 捕捉窗口中的相空间运动趋势;
- ④ **PINN 保持动力学一致**: 限制预测更新不要明显违背 Lorenz-96 方程;
- ⑤ **Scheduled sampling 贴近 rollout**: 训练阶段提前接触模型自身预测输入。

局限性

- Lorenz-96 只测试 $N = 10$ 、 $F = 8.0$ ，尚未覆盖更多维度和参数；
- 训练轮数统一为 20，未进行大规模超参数搜索；
- 当前结果主要来自单随机种子，缺少均值和方差；
- Ultimate Hybrid 还可继续做更细的 full ablation，例如 Transformer+PINN、Hybrid+PINN 等组合。

- ① Lorenz-63 说明短期预测可学，但 recursive rollout 会迅速暴露长期误差累积；
- ② Lorenz-96 10D 的核心评价应是 500-step rollout，而不是 one-step RMSE；
- ③ Residual learning、PINN、Transformer、Hybrid physics 和 scheduled sampling 分别从不同角度改善长期稳定性；
- ④ Ultimate Hybrid 以 12.80 的最终累计 RMSE 取得最佳结果；
- ⑤ 高维混沌预测更有效的路线是 “物理模型作为基底，深度学习修正残差”。

LLM 的作用

- 帮助从“单步预测模型比较”升级为“长期多步预测架构设计”；
- 辅助梳理 Ultimate Hybrid 的模块逻辑和公式表达；
- 根据张量形状和报错信息辅助定位 scheduled sampling 的窗口拼接问题。

验证原则

提示词必须给出上下文；LLM 只提供协作支持，所有数值结论均以 Python 输出和 CSV 文件为准。

谢谢！

欢迎提问